Mudasir Shafiq

LEAD DATA ENGINEER | PLATEFORMES DATA CLOUD | GOUVERNANCE ET IA

Paris, France | +33 7 75 73 96 00 | chmudasir.fr@gmail.com | LinkedIn | GitHub | Portfolio

PROFIL PROFESSIONNEL

Data Engineer avec plus de 4 ans d'expérience dans la conception et la livraison de plateformes data cloud, de pipelines batch et streaming, de modèles analytiques et de produits data intégrant l'IA. Solide maîtrise de Python et SQL, avec une expérience pratique d'Airflow, Kafka, dbt, Spark, PostgreSQL, BigQuery, Redshift, Snowflake, AWS, GCP et Azure. Conçoit des systèmes sécurisés et traçables intégrant contrôles de qualité, lignage, référentiels versionnés, RBAC, déploiements automatisés et supervision en production, adaptés aux environnements d'entreprise exigeants en matière de qualité et de conformité.

Architecture et responsabilité technique

Conception de solutions de bout en bout, modélisation des données, patterns d'intégration, planification de la livraison et mise en production.

Ingénierie data fiable

Ingestion batch et streaming, orchestration, transformation, tests, observabilité et optimisation des performances.

Gouvernance et auditabilité

Règles de validation, lignage, reproductibilité, mappings versionnés, historique d'audit immuable et accès contrôlé.

Livraison transverse

Transformation des besoins métier et analytiques en modèles de données, API, tableaux de bord et rapports maintenables.

EXPÉRIENCE PROFESSIONNELLE

Data and AI Engineer

Juil. 2026 - Aujourd'hui

Growlytics | À distance

- Responsable de l'architecture data de bout en bout d'une plateforme multi-tenant de veille concurrentielle, incluant la modélisation PostgreSQL et l'ingestion serverless depuis Meta Ad Library, Google Ads Transparency, TikTok via Apify, Meta Marketing et Google Ads API.
- Construction de pipelines déterministes de métriques de performance et d'analyses Claude et Gemini fondées sur les données, en séparant les preuves calculées des textes générés afin d'obtenir des résultats traçables et vérifiables.
- Automatisation de l'ingestion planifiée, de la génération des rapports, de la facturation et de l'envoi d'e-mails avec Vercel, Blob storage, des workflows cron, Paddle et Resend.

Data and AI Engineer / Full Stack Engineer

Juin 2026 - Aujourd'hui

GrowMore et Collabs+ | Dubaï / À distance

- Conception et réalisation de services pour une plateforme à forte intensité de données avec Next.js, FastAPI, PostgreSQL, SQLAlchemy, Alembic, Pydantic, JWT/RBAC, cache Redis, ingestion de fichiers et workflows d'e-mails en arrière-plan.
- Modélisation du domaine Collabs+ sur 9 modules métier et 35 tables PostgreSQL avec contraintes relationnelles, contrôle d'accès par rôle, suppression logique, historique d'audit immuable et préférences de notification pilotées par l'utilisateur.
- Définition de flux scalables de matching IA et de données temps réel avec pgvector et IVFFlat, Celery et Redis, Socket.IO Pub/Sub, Cloudflare R2, OpenAI et PydanticAI.
- Mise en place de patterns de livraison conteneurisés, d'environnements isolés, de CI/CD, de supervision et d'une architecture de déploiement sécurisée Nginx/TLS.

Consultant Data Engineering

Fév. 2026 - Juil. 2026

Watershed | Contrat | Paris / À distance

- Conception de modèles normalisés reliant produits, nomenclatures, procédés de fabrication et facteurs environnementaux pour des calculs d'impact produit traçables.
- Création de workflows ETL reproductibles pour standardiser les unités, valider les clés et les mappings, et préserver le lignage des données brutes vers les données normalisées issues de tableurs et catalogues.
- Mise en place de mappings de référence versionnés et de contrôles qualité sur les correspondances ambiguës, facteurs manquants, incohérences d'unités et calculs aval reproductibles.

EXPÉRIENCE PROFESSIONNELLE - SUITE

Data Engineer
Déc. 2023 - Juin 2024

Ceres-Advisory | Blockchain et Web3 | Paris

- Architecture d'un pipeline temps réel GA4 vers BigQuery via GTM, réduisant la latence de reporting de plusieurs heures à quelques minutes sur plus de 15 tableaux de bord KPI.
- Optimisation de jeux de données blockchain de plusieurs millions de lignes par partitionnement et fonctions de fenêtre, avec une réduction de 60 % du temps d'exécution SQL.
- Conception d'une ingestion AWS résiliente avec Lambda, Step Functions et S3, sans défaillance de pipeline après mise en production.
- Développement d'un pipeline de sentiment DistilBERT et exposition des résultats via Power BI et des vues de supervision Grafana.

Data Analyst et Performance Marketing
Janv. 2022 - Sept. 2023

PriceOye | E-commerce | Pakistan

- Maintien d'un ROAS de 6,33x à 43x et contribution à un GMV mensuel de 18 M PKR grâce à l'optimisation data-driven des campagnes et à l'analyse des audiences.
- Progression de la rétention client de 10 % à 15 % grâce à une segmentation d'audience assistée par IA et à des campagnes lifecycle automatisées.
- Automatisation des pipelines Power BI et des tableaux de bord KPI, supprimant plus de 10 heures de reporting manuel par semaine.

PROJETS DATA ENGINEERING SÉLECTIONNÉS

Intelligence pour l'élevage
Kafka | Airflow | BigQuery | scikit-learn

Construction d'un pipeline Kafka vers BigQuery orchestré par Airflow, avec feature engineering par CTE, validation et fonctions de fenêtre LAG sur des séries temporelles continues. Préparation de variables prêtes pour la classification de santé, la prédiction de fertilité et la régression du rendement laitier.

Pipeline ETL Reddit
Airflow | Terraform | AWS | dbt | Redshift | Tableau

Automatisation de l'ingestion AWS avec Airflow et Terraform, puis modélisation de transformations Data Vault 2.0 dans dbt et Redshift. Publication de jeux de données analytiques organisés via des tableaux de bord Tableau reproductibles.

Moteur de données synthétiques
Python | Règles de validation | Google Sheets

Génération de jeux de données quotidiens configurables avec contraintes par champ et validation des règles métier. Mise en place d'upserts Google Sheets idempotents pour éviter les doublons et fiabiliser les tests aval.

EXPERTISE TECHNIQUE

Programmation : Python, SQL, TypeScript, JavaScript

Plateformes : PostgreSQL, BigQuery, Snowflake, Redshift, Databricks, Redis, pgvector

Gouvernance et qualité : Lignage, validation, versioning, audit, normalisation d'unités, mappings

DevOps : Docker, Kubernetes, Terraform, GitHub Actions, CI/CD, Nginx, Linux

Ingénierie data : Airflow, Kafka, Spark, Hadoop, dbt, ETL/ELT, streaming, Data Vault 2.0

Cloud : AWS, GCP, Azure, S3, Lambda, Step Functions, Vercel, Cloudflare R2

Sécurité et API : FastAPI, REST, Pydantic, JWT, RBAC, NextAuth, isolation tenant

Analytique et IA : Power BI, Tableau, Grafana, GA4, OpenAI, Claude, Gemini, scikit-learn

FORMATION, CERTIFICATIONS ET LANGUES

FORMATION

MSc Data Engineering
Aivancity University Paris | 2023 - 2024

BS Mathematics
Air University | 2016 - 2020

CERTIFICATIONS

AWS Cloud Practitioner
IBM Data Engineer
Google Data Analytics
Machine Learning - Coursera

LANGUES

Anglais
Avancé

Français
A2 / B1