

CONTACT

Paris, France
+33 7 75 73 96 00
chmudasir.fr@gmail.com
LinkedIn • GitHub
Portfolio

COMPÉTENCES TECHNIQUES

Programmation
Python, SQL
TypeScript, JavaScript

Ingénierie data
Airflow, Kafka, Spark, Hadoop
dbt, ETL/ELT, streaming
Data Vault 2.0

Bases et entrepôts
PostgreSQL, BigQuery
Snowflake, Redshift, Databricks
Redis, pgvector

Cloud
AWS, GCP, Azure
S3, Lambda, Step Functions
Vercel, Cloudflare R2

Gouvernance et qualité
Lignage, validation, versioning
audit, normalisation d'unités
mappings de référence

Backend et API
FastAPI, REST, Django, SQLAlchemy
Alembic, Pydantic, JWT, RBAC
NextAuth, Celery, Socket.IO

Frontend
Next.js, React, Tailwind CSS

DevOps et infrastructure
Docker, Kubernetes, Terraform
GitHub Actions, CI/CD, Nginx
Linux, SSH, Let's Encrypt

IA et automatisation
OpenAI, Claude, Gemini
PydanticAI, scikit-learn, n8n

Analytique et observabilité
Power BI, Tableau, Grafana, GA4
PostHog, Sentry, Prometheus

Données durables
ACV, comptabilité carbone
modèles produit/BOM et processus
facteurs, lignage, versioning

FORMATION

MSc Data Engineering
Aivancity University Paris | 2023-2024

BS Mathematics
Air University | 2016-2020

CERTIFICATIONS

AWS Cloud Practitioner • IBM Data Engineer
Google Data Analytics • Machine Learning - Coursera

LANGUES

Anglais - Avancé | Français - A2/B1

Mudasir Shafiq

LEAD DATA ENGINEER | PLATEFORMES DATA CLOUD | GOUVERNANCE ET IA

Data Engineer avec plus de 4 ans d'expérience dans l'architecture et la livraison de plateformes data cloud, de pipelines batch et streaming, de modèles analytiques et de produits data intégrant l'IA. Solide maîtrise de Python et SQL avec Airflow, Kafka, dbt, Spark, PostgreSQL, BigQuery, Redshift, Snowflake, AWS, GCP et Azure. Conçoit des systèmes sécurisés et traçables avec contrôles qualité, lignage, référentiels versionnés, RBAC, CI/CD et supervision.

EXPÉRIENCE

Data and AI Engineer — **Juil. 2026-Aujourd'hui**
Growlytics | À distance

- Responsable de l'architecture data d'une plateforme multi-tenant de veille concurrentielle, avec modélisation PostgreSQL et ingestion serverless depuis Meta Ad Library, Google Ads Transparency, TikTok via Apify, Meta Marketing et Google Ads API.
- Construction de pipelines déterministes de métriques et d'analyses Claude/Gemini fondées sur les données, séparant les preuves calculées des textes générés.
- Automatisation de l'ingestion, des rapports, de la facturation et des e-mails avec Vercel, Blob storage, cron, Paddle et Resend.

Data and AI Engineer / Full Stack Engineer — **Juin 2026-Aujourd'hui**
GrowMore et Collabs+ | Dubaï / À distance

- Conception de services data avec Next.js, FastAPI, PostgreSQL, SQLAlchemy, Alembic, Pydantic, JWT/RBAC, cache Redis, ingestion de fichiers et e-mails asynchrones.
- Modélisation de Collabs+ sur 9 modules et 35 tables PostgreSQL avec contraintes, contrôle d'accès, suppression logique, audit immuable et préférences de notification.
- Définition du matching IA et des flux temps réel avec pgvector/IVFFlat, Celery/Redis, Socket.IO Pub/Sub, Cloudflare R2, OpenAI et PydanticAI.
- Mise en place de la livraison conteneurisée, d'environnements isolés, de CI/CD, de supervision et d'un déploiement Nginx/TLS sécurisé.

Consultant Data Engineering — **Fév. 2026-Juil. 2026**
Watershed | Contrat | Paris / À distance

- Conception de modèles normalisés reliant produits, nomenclatures, procédés de fabrication et facteurs environnementaux pour des calculs d'impact traçables.
- Création de workflows ETL reproductibles standardisant les unités, validant clés et mappings, et préservant le lignage des données brutes aux données normalisées.
- Mise en place de mappings versionnés et de contrôles qualité sur les correspondances ambiguës, facteurs manquants, incohérences d'unités et calculs aval.

Data Engineer — **Déc. 2023-Juin 2024**
Ceres-Advisory - Blockchain et Web3 | Paris

- Architecture d'un pipeline temps réel GA4 vers BigQuery via GTM, réduisant la latence de plusieurs heures à quelques minutes sur plus de 15 tableaux KPI.
- Optimisation de données blockchain de plusieurs millions de lignes par partitionnement et fonctions de fenêtre, réduisant le temps SQL de 60 %.
- Conception d'une ingestion AWS résiliente avec Lambda, Step Functions et S3, sans défaillance après mise en production.
- Développement d'un pipeline de sentiment DistilBERT et exposition des résultats dans Power BI et Grafana.

Data Analyst et Performance Marketing — **Janv. 2022-Sept. 2023**
PriceOye - E-commerce | Pakistan

- Maintien d'un ROAS de 6,33x à 43x et contribution à un GMV mensuel de 18 M PKR grâce à l'optimisation data-driven et à l'analyse d'audience.
- Hausse de la rétention de 10 % à 15 % via la segmentation d'audience assistée par IA et les campagnes lifecycle automatisées.
- Automatisation des pipelines Power BI et des tableaux KPI, supprimant plus de 10 heures de reporting manuel par semaine.

PROJETS DATA ENGINEERING SÉLECTIONNÉS

Intelligence pour l'élevage | ***Kafka • Airflow • BigQuery • scikit-learn***

- Pipeline Kafka vers BigQuery orchestré par Airflow avec validation, feature engineering par CTE et fonctions de fenêtre LAG.
- Préparation de variables prêtes pour la classification de santé, la prédiction de fertilité et la régression du rendement laitier.

Pipeline ETL Reddit | ***Airflow • Terraform • AWS • dbt • Redshift • Tableau***

- Ingestion AWS automatisée avec Airflow et Terraform, puis transformations Data Vault 2.0 dans dbt et Redshift.
- Publication de jeux analytiques organisés via des tableaux de bord Tableau reproductibles.

Moteur de données synthétiques | ***Python • Validation • Google Sheets***

- Génération de jeux de données quotidiens configurables avec contraintes par champ et validation des règles métier.
- Upserts Google Sheets idempotents pour éviter les doublons et fiabiliser les tests aval.